

Promovendo Acessibilidade com Inteligência Artificial: Desenvolvimento de um Sistema para Tradução de LIBRAS

Jean Souza¹, Laura Fonseca¹, Rafael Franco¹, Felipe Fernandes¹

¹ Laboratory of Technological Innovation in Health (LAIS), Federal University of Rio Grande do Norte (UFRN), Natal, Rio Grande do Norte, Brazil

Abstract

A Inteligência Artificial (IA) tem se mostrado uma ferramenta fundamental para promover acessibilidade e inclusão social, especialmente para pessoas com deficiência, e este estudo explora o desenvolvimento de um sistema de tradução em tempo real da Língua Brasileira de Sinais (LIBRAS) utilizando IA, com o objetivo de melhorar a comunicação entre surdos e ouvintes e garantir um acesso equitativo à informação. O sistema capturou gestos com uma câmera convencional, empregando um modelo de classificação treinado para reconhecer as letras do alfabeto manual de LIBRAS. Os resultados demonstraram uma acurácia de 50,58% no reconhecimento das letras, embora algumas apresentassem desempenho variável devido à limitação das amostras de treinamento. Além disso, foi incorporado um componente de texto-para-fala (TTS), o que contribuiu para melhorar a acessibilidade ao facilitar a compreensão para ouvintes. Apesar do bom desempenho, a variabilidade na detecção dos gestos destaca a necessidade de expandir o conjunto de dados de treinamento e aprimorar os modelos de reconhecimento. Embora a tecnologia mostre um grande potencial para promover inclusão social, é necessário otimizar a precisão, confiabilidade e naturalidade da comunicação. O estudo sugere que as versões futuras do sistema devem focar na ampliação do banco de dados e no refinamento dos modelos, a fim de melhorar a performance e proporcionar uma experiência mais eficaz e fluida, destacando o potencial da IA como uma ferramenta poderosa para a inclusão social.

Palavras-Chave: LIBRAS, Inclusão Social, Inteligência Artificial, Reconhecimento de Gestos, Aprendizado de Máquina, Visão Computacional.

1. Introdução

A inclusão social, um pilar fundamental para a construção de sociedades equitativas e justas, preconiza a participação plena de todos os indivíduos, sem distinção de suas características ou condições, em todos os âmbitos da vida social. Para as pessoas com deficiência, a inclusão significa a superação de barreiras que impedem o exercício da autonomia, o acesso a oportunidades e a possibilidade de viver uma vida plena e digna. No mundo, estima-se que mais de um bilhão de pessoas convivam com algum tipo de deficiência, enfrentando desafios diários para realizar atividades cotidianas (Organização Mundial da Saúde; Banco Mundial, 2011). Aproximadamente 200 milhões dessas pessoas enfrentam dificuldades significativas na execução de suas atividades diárias (Organização Mundial da Saúde; Banco Mundial, 2011).

A gama de dificuldades encontradas por pessoas com deficiência é extensa e impacta diretamente sua qualidade de vida. A falta de acessibilidade em ambientes físicos e virtuais, a discriminação, o preconceito, a dificuldade de acesso à educação e ao mercado de trabalho, e a limitação de recursos de comunicação e locomoção são apenas alguns dos obstáculos que esse grupo enfrenta. Muitas vezes, as tecnologias assistivas disponíveis não minimizam as dificuldades encontradas, especialmente para o acesso seguro em ambientes cotidianos (García, 2017). Um dos exemplos são os sistemas de transporte público que, apesar dos avanços em segurança e acessibilidade, ainda apresentam desafios para pessoas com deficiência, principalmente em relação à acessibilidade, segurança e atitudes dos motoristas (Hezam et al., 2023).

Em face a esse panorama, a inteligência artificial (IA) emerge como uma ferramenta poderosa com grande potencial para promover a inclusão social de pessoas com deficiência. Através de seus algoritmos e técnicas de aprendizado de máquina, a IA viabiliza a criação de tecnologias assistivas inovadoras e personalizadas, capazes de auxiliar na superação de diversas barreiras, adaptando-se dinamicamente às condições do indivíduo e às características do ambiente (Fernández-Ríos; Buela-Casal, 2009; Ackland et al., 2017).

É fundamental salientar que o desenvolvimento de tecnologias de IA para a inclusão deve ser pautado por princípios de acessibilidade, usabilidade e ética, garantindo que as soluções atendam às reais necessidades dos usuários. A participação ativa de pessoas com deficiência no processo de design e desenvolvimento dessas tecnologias é crucial (van Toorn, 2024).

Levando em conta o cenário exposto, fica claro que a inclusão social de indivíduos com deficiência exige a superação de obstáculos que restringem seu acesso a várias áreas da vida diária. A ausência de tecnologias assistivas eficientes e a continuidade de desafios em contextos físicos e virtuais demandam soluções inovadoras que satisfaçam as demandas deste grupo. A inteligência artificial (IA), com sua capacidade de desenvolver tecnologias customizadas e ajustáveis, se apresenta como um recurso promissor para fomentar a inclusão e a independência desses indivíduos, ao mesmo tempo que auxilia na criação de um ambiente mais acessível e equitativo.

Este estudo tem como objetivo a criação de uma tecnologia de assistência baseada em Inteligência Artificial (IA), utilizando algoritmos de aprendizado automático para identificar sinais da Língua Brasileira de Sinais (LIBRAS). O sistema sugerido visa simplificar a comunicação entre indivíduos surdos e ouvintes, fomentando a inclusão social e o acesso justo à informação. Ele é guiado por princípios de acessibilidade, ética e usabilidade. Portanto, a contribuição deste estudo está na melhoria das tecnologias de inclusão, através da aplicação de uma solução prática e eficiente, que atenda às demandas reais dos usuários.

2. Trabalhos Relacionados

Para mais detalhes sobre trabalhos relacionados à inclusão social usando inteligência artificial, recomenda-se a leitura do artigo de revisão sistemática disponível [neste link](#).

3. Métodos

Conjunto de Dados

O conjunto de dados utilizado para o treinamento do modelo foi gerado através da plataforma Teachable Machine do Google. O modelo foi treinado para reconhecer gestos representando letras da Língua Brasileira de Sinais (LIBRAS). Para isso, foram coletadas imagens de diferentes sinais das mãos, cada uma representando uma letra específica da LIBRAS. O conjunto de dados contém 21 classes (uma para cada letra, considerando apenas os sinais estáticos, desconsiderando as letras com sinais de movimento como: ‘H’, ‘J’, ‘K’, ‘X’ e ‘Z’) e foi composto por diversas amostras de cada classe, capturadas sob diferentes condições de iluminação e posições das mãos. As imagens foram previamente rotuladas de acordo com as letras correspondentes, e as amostras foram organizadas em uma estrutura de pastas, onde cada pasta correspondia a uma classe de letra.




Figura 1 - coleta das imagens

Técnica Utilizada

A principal técnica utilizada neste trabalho foi o reconhecimento de gestos através de uma Rede Neural Artificial (RNA) treinada utilizando aprendizado supervisionado. O treinamento realizado na plataforma Teachable Machine, permite simplificar a criação de modelos de aprendizado de máquina, permitindo a exportação do modelo treinado no formato .h5.

O processo de treinamento envolveu as seguintes etapas:

1. **Coleta e Rotulagem de Dados:** Captura de imagens dos gestos das mãos, cada uma representando uma letra específica da LIBRAS. As imagens foram rotuladas manualmente.
2. **Pré-processamento de Dados:** As imagens foram redimensionadas para um tamanho fixo de 300x300 pixels para uniformidade. As amostras foram organizadas em pastas, com cada pasta representando uma classe (letra).
3. **Divisão de Dados:** O conjunto de dados foi dividido em conjuntos de treinamento e validação. A divisão típica é de 80% para treinamento e 20% para validação.
4. **Treinamento do Modelo:** A RNA foi treinada usando o conjunto de dados de treinamento. A arquitetura da rede neural foi configurada na Teachable Machine, que suporta a adição de camadas convolucionais, de pooling e totalmente conectadas, ajustando hiperparâmetros como taxa de aprendizado, épocas e tamanho do lote (batch size). Durante o treinamento, o algoritmo de backpropagation foi utilizado para ajustar os pesos da rede com base nos erros das previsões.

5. **Validação do Modelo:** O desempenho do modelo foi validado utilizando o conjunto de validação. A precisão (accuracy) foi monitorada durante o treinamento para evitar o overfitting e garantir a generalização do modelo.
6. **Exportação do Modelo:** Após o treinamento, o modelo foi exportado no formato .h5 para ser utilizado no código Python para classificação em tempo real.

As funcionalidades do sistema desenvolvido, abordado neste estudo, se caracterizam da seguinte forma:

- **Reconhecimento de Gestos em Tempo Real:**
 - Utilizando a câmera, os gestos realizados pelo usuário são capturados e processados em tempo real.
 - Cada gesto é classificado como uma letra correspondente da LIBRAS.
- **Construção de Palavras:**
 - As letras reconhecidas são concatenadas dinamicamente para formar palavras.
 - O sistema permite pausar ou reiniciar a construção de palavras com comandos específicos:
 - 'N': Inicia uma nova palavra.
 - 'P': Pausa a adição de letras e lê a palavra formada em voz alta.
 - 'C': Limpa a palavra atual.
 - 'Q': Encerra o programa.
- **Leitura em Voz Alta:**
 - Após formar uma palavra, o sistema utiliza a biblioteca **pyttsx3** para reproduzir a palavra em voz alta.
 - Uma funcionalidade adicional permite a leitura de mensagens em threads separadas para evitar bloqueios no fluxo de execução.
- **Feedback Visual:**
 - O sistema exibe informações como a letra reconhecida, a confiança da classificação e a palavra formada diretamente na tela.
 - Frames intermediários, como o recorte da mão e a imagem pré-processada, também são exibidos para facilitar o monitoramento.
- **Integração de Módulos Avançados:** Além disso, foi utilizada uma biblioteca para facilitar a integração de módulos de detecção de mão e de classificação. A cvzone é uma biblioteca de visão computacional que fornece funcionalidades para rastreamento

de mãos, reconhecimento de gestos, entre outras. No código, foram utilizadas as seguintes funcionalidades da biblioteca:

- **HandDetector:** Este módulo detecta as mãos em imagens e fornece informações detalhadas, como localização e tamanho das mãos. Essa funcionalidade é essencial para isolar a região de interesse (a mão) antes da classificação.
- **Classifier:** O módulo Classifier utiliza o modelo treinado no formato .h5 para realizar a classificação de imagens. Ele fornece métodos como `getPrediction`, que:
 - Recebe como entrada a imagem capturada.
 - Classifica a imagem com base no modelo treinado.
 - Retorna a classe com maior probabilidade e a confiança da predição.
- **Melhorias de Usabilidade:**
 - O sistema só adiciona uma nova letra se ela for diferente da última detectada e se a confiança for superior a 90%, reduzindo ruídos e classificações erradas.
 - Comandos intuitivos para reiniciar, pausar e encerrar aumentam a acessibilidade.

O processo de reconhecimento de gestos pode ser descrito no seguinte pseudocódigo:

Algoritmo 1: Algoritmo de Reconhecimento de Gestos	
Entrada	: Imagem capturada pela câmera
Saída	: Letra reconhecida e palavra construída
Dados	: Modelo treinado (<code>keras_model.h5</code>), Labels (<code>labels.txt</code>)
Resultado:	Palavra construída a partir dos gestos reconhecidos
1	Inicializar a câmera;
2	Inicializar o detector de mãos para detectar até uma mão por vez;
3	Carregar o modelo treinado para reconhecer gestos (<code>keras_model.h5</code>);
4	Carregar os rótulos para identificar cada gesto (<code>labels.txt</code>);
5	Configurar o assistente de voz para fornecer feedback ao usuário;
6	Ajustar a voz (velocidade e volume);
7	Anunciar instruções para o usuário, explicando como utilizar o sistema;
8	while a câmera estiver ligada do
9	Capturar uma nova imagem da câmera;
10	Detectar se há uma mão na imagem;
11	se uma mão for detectada e a captura da palavra estiver em andamento então
12	Obter a posição e o tamanho da mão detectada;
13	se a mão estiver detectada de forma válida então
14	Recortar a região da imagem onde a mão está;
15	Ajustar a imagem para o tamanho fixo de 300x300 pixels;
16	Classificar o gesto feito pela mão usando o modelo carregado;
17	Obter a predição e a confiança do modelo (quão confiante o modelo está sobre o gesto identificado);
18	se a confiança for maior que 90% e a letra reconhecida for diferente da última então
19	Adicionar a letra reconhecida à palavra que está sendo formada;
20	Atualizar a última letra detectada;
21	fim
22	Mostrar na tela a letra detectada, o nível de confiança e a palavra formada até o momento;
23	fim
24	fim
25	se a tecla pressionada for 'c' então
26	Limpar a palavra formada até agora;
27	Reiniciar o processo de captura de letras;
28	Anunciar que a palavra foi limpa e que o usuário pode começar a formar uma nova palavra;
29	fim
30	se a tecla pressionada for 'n' então
31	Iniciar a formação de uma nova palavra;
32	Anunciar que uma nova palavra está começando e que o usuário pode iniciar os gestos;
33	fim
34	se a tecla pressionada for 'p' então
35	Pausar a captura da palavra;
36	Anunciar qual é a palavra formada até o momento e que o usuário pode pressionar 'n' para iniciar uma nova palavra;
37	fim
38	se a tecla pressionada for 'q' então
39	Encerrar o programa;
40	Anunciar que o programa será encerrado e que a execução chegou ao fim;
41	fim
42	se a palavra formada estiver pausada e não estiver vazia então
43	Anunciar a palavra formada;
44	fim
45	end

Figura 2 - pseudocódigo do sistema

O fluxo principal do processo é capturar o gesto da mão em tempo real usando a câmera, isolar a região da mão, redimensionar a imagem para um tamanho fixo (300x300 pixels) e, em seguida, usar o modelo de classificação para identificar a letra associada ao gesto. A letra

detectada é adicionada à palavra construída, desde que a confiança da classificação seja maior que 90% e a letra seja diferente da última identificada.

Métricas de Avaliação

A principal métrica de avaliação utilizada para o desempenho do modelo foi a taxa de precisão (accuracy), que é a porcentagem de classificações corretas realizadas pelo modelo em relação ao total de tentativas. A confiança de cada predição também foi monitorada, e a palavra construída só é atualizada quando a confiança ultrapassa um limite de 90%. Isso ajuda a minimizar os erros de classificação.

Além disso, a confiabilidade do modelo foi avaliada ao observar o desempenho do sistema em condições variadas de iluminação e movimentos das mãos, que são fatores que afetam diretamente a precisão do reconhecimento. O sistema apresentou boa precisão em condições controladas, mas foi identificado que a variabilidade nas condições de captura pode impactar a performance.

4. Resultados Experimentais

Os resultados desta seção baseiam-se exclusivamente em experimentos conduzidos para avaliar o desempenho prático do sistema de tradução de LIBRAS em tempo real. Os experimentos foram realizados em um ambiente controlado, utilizando uma câmera convencional para capturar os gestos e um modelo de classificação previamente treinado para interpretar as letras do alfabeto manual.

Os testes tiveram como objetivo verificar a funcionalidade das principais características do sistema, como a precisão no reconhecimento de gestos, a resposta dos comandos de controle e a interação em tempo real entre o usuário e o sistema.

Funcionamento do sistema

A partir da visualização gráfica pela câmera de vídeo, foi possível sinalizar as letras do alfabeto, gesticulando com as mãos, e o sistema captou de forma correta as mãos e seus pontos de movimento, utilizando a biblioteca de reconhecimento de mãos.




Figura 3 - pontos da mão

Dessa forma, o sistema pode ser testado ao ser mostrado os sinais para que o modelo faça a predição do sinal, trazendo a letra correspondente e o seu nível de acurácia.




Figura 4 - detecção da letra “o”

Como mostrado na figura, ao ser sinalizada a letra “o” o sistema reconheceu com precisão de 95.47% e então, como a lógica está configurada para apenas aceitar letras com acurácia maior de 90% na formação da palavra, a letra “o” sinalizada foi adicionada à palavra, onde está o “word:”.

Os testes foram feitos com todas as letras presentes no modelo, e para algumas letras a detecção ainda se encontra imprecisa, como é o caso da letra “u”.



Figura 5 - detecção da letra “u”

Por mais que esteja sinalizando a letra “u” em LIBRAS, o sistema não consegue captar com precisão e ainda ocorre confusões entre as letras, onde, como podemos ver na figura, o sinal foi confundido com a letra “m”.

O sistema consegue formar a palavra a partir da sequência de sinais de letras apresentadas da forma como foi planejado. O usuário gesticula os sinais das letras em sequência para ser formada a palavra e após formar a palavra corretamente o sistema foi capaz de ler em voz alta com a assistente de voz da biblioteca utilizada com sucesso.




Figura 6 - formação de palavra

Como pode-se observar na figura acima, foram adicionadas as letras “o”, “l”, “a” à sequência para a formação da palavra e obteve-se a palavra “ola”, onde foi lida e interpretada pela assistente de voz corretamente, mostrando um ótimo desempenho dessa funcionalidade.

Desempenho do modelo

O sistema em questão foi avaliado utilizando um conjunto de dados amostrais (em ambientes e situações um pouco diferentes do que o modelo foi treinado), e de métricas de desempenho, incluindo perda (loss), acurácia, precisão, recall, F1-score, e média ponderada. Estas métricas fornecem uma visão detalhada sobre a capacidade do modelo de reconhecer e traduzir corretamente os sinais de cada letra em LIBRAS em texto escrito, abordando também a precisão e a generalização do modelo em relação a diferentes sinais.

A avaliação do modelo mostrou um desempenho desigual entre as diferentes classes, possuindo uma acurácia geral de 50.58%.




Figura 7 - desempenho por métrica

A precisão apresentou variação significativa entre as classes. Algumas classes, como a classe da letra “Y”, mostraram uma precisão perfeita de 1.00, indicando que o modelo foi altamente preciso ao prever essa classe. No entanto, outras classes, como a classe da letra “T”, apresentaram precisão muito baixa (0.07), sugerindo que o modelo comete muitos erros ao classificar essas letras.

O recall também variou consideravelmente, com algumas classes apresentando resultados excepcionais, como a classe da letra “B” com 0.99 de recall, indicando que o modelo é altamente eficaz em identificar corretamente essa classe. Por outro lado, classes como a classe da letra “N” e a classe da letra “U” tiveram recall muito baixo, com valores de 0.06 e 0.07, o que indica que o modelo tem dificuldades significativas em detectar essas classes.

O F1-score, que é uma média ponderada entre precisão e recall, refletiu o desempenho geral do modelo. Algumas classes, como a classe da letra “P”, tiveram um F1-score muito alto (0.98), o que demonstra que o modelo obteve um bom equilíbrio entre precisão e recall para

essas classes. No entanto, classes como classe da letra “N” (0.11) e classe da letra “T”(0.07) apresentaram F1-scores muito baixos, indicando que o modelo não conseguiu equilibrar bem esses dois fatores para essas classes.

5. Discussões

Os experimentos realizados para avaliar o sistema de tradução de LIBRAS em tempo real evidenciam tanto os avanços quanto as limitações do modelo proposto. O desempenho geral do sistema foi satisfatório em diversas áreas, como o reconhecimento de gestos em tempo real e a formação correta de palavras a partir de sinais. Essa funcionalidade é crucial para viabilizar a comunicação inclusiva e reforça o potencial de tecnologias baseadas em visão computacional e aprendizado de máquina para promover a acessibilidade.

O uso do assistente de voz (TTS) foi uma adição importante, permitindo que as palavras formadas fossem convertidas em fala clara, o que amplia a acessibilidade do sistema. Isso não apenas favorece a tradução de LIBRAS para ouvintes, mas também possibilita que pessoas cegas possam interagir com o sistema por meio da comunicação auditiva, promovendo maior inclusão. A utilização de bibliotecas e técnicas de TTS robustas contribuiu para a clareza da fala gerada, mas também apresentou limites na reprodução de nuances de entonação e naturalidade. Em um cenário ideal, futuras implementações poderiam buscar aprimorar a qualidade da síntese de fala para garantir uma comunicação ainda mais eficiente.

No entanto, os resultados mostram que o modelo apresenta desempenho desigual entre diferentes classes de letras. Por exemplo, enquanto algumas letras, como “Y” e “P”, atingiram altos valores de precisão e F1-score, outras, como “N”, “T” e “U”, tiveram desempenho significativamente inferior. Esse comportamento sugere que o modelo enfrenta dificuldades em generalizar corretamente para sinais com características similares ou que apresentam maior variabilidade em sua execução.

A discrepância no desempenho pode estar relacionada à qualidade e diversidade do conjunto de dados utilizados para treinamento. A baixa precisão e recall de certas classes indicam que o modelo pode ter sido treinado com um número insuficiente de exemplos representativos para essas letras ou que os sinais possuem características ambíguas que confundem o classificador. Essa limitação reforça a necessidade de expandir o conjunto de dados com amostras mais diversificadas, cobrindo diferentes estilos de sinalização e contextos ambientais.

Além disso, os resultados mostram que, apesar da precisão geral de 50,58%, o sistema é capaz de apresentar um desempenho superior em condições controladas, o que é encorajador para aplicações práticas. No entanto, para alcançar um uso robusto e inclusivo em cenários reais, é essencial aprimorar o modelo, explorando novas abordagens.

6. Conclusões

Os resultados experimentais demonstraram que o sistema de tradução de LIBRAS em tempo real, embora promissor, ainda enfrenta desafios importantes em relação à precisão e generalização dos sinais. A acurácia geral do modelo, que foi de 50.58%, revelou um desempenho desigual entre as diferentes letras do alfabeto, com algumas classes apresentando precisão quase perfeita e outras apresentando resultados insatisfatórios. A letra "Y", por exemplo, teve uma precisão de 1.00, enquanto a letra "T" apresentou uma precisão de apenas 0.07, o que reflete as dificuldades do modelo em reconhecer certos gestos com consistência. Apesar dessas limitações, o sistema foi eficaz na tradução de palavras quando os gestos eram corretamente reconhecidos, atingindo um desempenho satisfatório na formação de palavras e na utilização do assistente de voz (TTS) para converter a sequência de sinais em fala clara. Isso representa um avanço significativo para a acessibilidade, pois além de beneficiar pessoas ouvintes, também promove a inclusão de pessoas cegas, permitindo-lhes interagir com o sistema por meio da comunicação auditiva.

Os testes também destacaram que o modelo enfrenta dificuldades em gestos de algumas letras, como a letra "u", que foi confundida com outras letras, como a "m". Esse comportamento foi atribuído à falta de diversidade nas amostras de treinamento, o que limita a capacidade do modelo de generalizar para diferentes usuários e condições. Se o modelo fosse treinado com dados mais diversos, incluindo variações de iluminação, diferentes gestos realizados por mãos de diversas pessoas e ambientes variados, a precisão do sistema poderia melhorar significativamente. A diversidade de dados ajudaria o modelo a aprender a reconhecer melhor as variações nos sinais e a adaptar-se a diferentes contextos, aumentando a robustez do sistema.

Futuramente, será essencial expandir o conjunto de dados de treinamento, incluindo uma maior variedade de gestos e condições ambientais, para melhorar a robustez do sistema e sua capacidade de adaptação a diferentes cenários. Além disso, a implementação de técnicas mais avançadas de aprendizado de máquina poderia contribuir para o aprimoramento do modelo.

O sistema demonstrou potencial para reconhecer sinais de LIBRAS em tempo real, mas o aprimoramento do modelo depende da ampliação do banco de dados e da implementação de técnicas mais avançadas de aprendizado de máquina. A melhoria da precisão do reconhecimento de gestos, especialmente para letras problemáticas, é um passo crucial para alcançar um sistema mais confiável e eficiente.

Em resumo, o sistema apresenta um bom ponto de partida para a tradução de LIBRAS em tempo real, com destaque para a utilização do assistente de voz para conversão de texto em fala. No entanto, é necessário investir na melhoria da precisão do reconhecimento de gestos e na expansão do conjunto de dados para garantir maior consistência e robustez, o que contribuirá para a evolução do sistema e para uma melhor experiência de usuário, promovendo a inclusão social e a eficácia da tradução de LIBRAS em diversas aplicações do mundo real.

Material Suplementar

A apresentação do presente trabalho está disponível [neste link](#).

Referências

1. ORGANIZAÇÃO MUNDIAL DA SAÚDE; BANCO MUNDIAL. World report on disability. 2011. Disponível em: http://www.who.int/disabilities/world_report/2011/en/. Acesso em: 27 nov. 2024.
2. BRASIL, Livro Branco da Tecnologia Assistiva; COVID, Painel. no Brasil. **São Paulo: ITS Brasil**, 2017.
3. HEZAM, Ibrahim M. et al. Assessing the barriers of digitally sustainable transportation system for persons with disabilities using Fermatean fuzzy double normalization-based multiple aggregation method. **Applied Soft Computing**, v. 133, p. 109910, 2023.
4. FERNÁNDEZ-RÍOS, Luis; BUELA-CASAL, Gualberto. Standards for the preparation and writing of Psychology review articles. **International journal of clinical and health psychology**, v. 9, n. 2, p. 329-344, 2009.
5. ACKLAND, Peter; RESNIKOFF, Serge; BOURNE, Rupert. World blindness and visual impairment: despite many successes, the problem is growing. **Community eye health**, v. 30, n. 100, p. 71, 2017.